

Industry Intelligence Agent

面試準備指南：專案導覽、抽取邏輯與分析方法

Joey Wu | Traditional Chinese Guide | Updated 2026-05-07

這份 guide 的目標是讓你能真正講清楚整個專案，不只是背功能清單。重點放在資料怎麼進來、KRI 怎麼被抽出來、嚴重度怎麼判斷，以及最後怎麼變成顧問式 insight。

1. 專案一句話

Industry Intelligence Agent 是一個用 Python 建立的產業情報分析 MVP。它把公司基本資料、新聞、年報文字和產業趨勢整理成 KRI 風險證據、dashboard-ready CSV、Excel workbook、Streamlit 儀表板，以及中英雙語顧問式報告。

面試講法

我做的是一個產業情報代理人。輸入公司、產業關鍵字和年報 PDF 後，系統會收集新聞、讀取年報、抽取 KRI 風險證據、判斷嚴重度，最後產生儀表板、Excel 和顧問式 brief。

專案分成三層

- Input layer：公司資料、新聞、年報、產業趨勢。
- Extraction layer：把文字轉成結構化證據列，例如 `kri_category`、`severity_hint`、`evidence_sentence`。
- Delivery layer：輸出 dashboard、Excel、Markdown/JSON report，讓顧問和 business user 能 review。

2. 系統架構與模組責任

模組	實際負責的事
app.py	Streamlit demo 入口。管理 sidebar inputs、session state、tabs、charts、download。
company_registry.py	公司資料 CSV 標準化、名稱 normalize、ticker/name 查找。
news_collector.py	讀 demo CSV 或 RSS feeds，依 keyword 過濾新聞，並去除重複文章。
annual_report_reader.py	用 pdfplumber 抽 PDF 文字，清理斷字/頁碼，找年報章節並切 chunks。
kri_extractor.py	用 12 類 KRI keyword dictionary 抽 evidence sentence，並打 severity hint。
industry_trend_reader.py	用關鍵字句子抽取 main trends、growth drivers、risks、DT opportunities。
report_generator.py	把 evidence 轉成 Markdown/JSON brief 和 dashboard-ready KPI/KRI table。
excel_report_generator.py	產生 Excel workbook，加入公式、篩選、條件格式。
pipeline.py	CLI 端到端流程，把所有模組串起來並輸出 CSV/JSON/MD/XLSX。

User input

- > company profile + news + annual report
- > KRI evidence extraction
- > severity / pivot / dashboard table
- > Excel + Streamlit + consulting brief

3. 真正的資料流

核心流程在 src/pipeline.py。它先建立 company anchor，再載入新聞與年報，接著抽 KRI，最後產生 dashboard-ready table 和報告。

```
registry_df = load_company_registry(registry_path)
company_profile = get_company_profile(registry_df, company_name=company)

news_df = _load_or_collect_news(company, industry, use_sample_data)
annual_text = _load_annual_report_text(annual_report, company, industry)

annual_text = clean_annual_report_text(annual_text)
annual_chunks = chunk_text(annual_text)

kri_df = _extract_all_kri(news_df, annual_text, company, industry)
dashboard_df = build_dashboard_kpi_kri_table(news_df, kri_df, trend_notes)
```

- news_df 代表外部市場訊號。
- annual_text 代表公司自己揭露的管理層語言。
- kri_df 是核心成果，每一列都是一個可回頭審查的風險證據句。
- dashboard_df 是給 Streamlit、Excel 或 Power BI 使用的彙總表。

4. 新聞與年報怎麼抽

新聞抽取

news_collector.py 支援 demo CSV 和 RSS。RSS 抓完後，會把 keyword 拆成 terms，對 title + summary 做 OR match。這樣 recall 較高，適合 MVP，但 precision 需要人審。

```
terms = [term.lower() for term in keyword.split()]
searchable_text = (df["title"] + " " + df["summary"]).str.lower()

mask = searchable_text.apply(
    lambda text: any(term in text for term in terms)
)
filtered_df = df.loc[mask].drop_duplicates(["url", "title"])
```

年報抽取

annual_report_reader.py 用 pdfplumber 抽 PDF 文字，再清理 PDF 常見問題，例如斷字、null character、單獨頁碼。接著用 section patterns 找 business overview、risk factors、financial overview、MD&A 等章節。

```
with pdfplumber.open(str(path)) as pdf:
    for page in pdf.pages:
        page_text = page.extract_text() or ""
        text_parts.append(page_text)

cleaned = re.sub(r"(\w)-\s*\n\s*(\w)", r"\1\2", text)
cleaned = re.sub(r"(?m)^\s*\d+\s*$", "", cleaned)
```

最後會切成 chunk_size=1200 words、overlap=150 words 的 chunks。Overlap 可以保留跨段落風險描述的上下文，未來接 LLM 或 semantic search 也比較穩。

5. KRI 怎麼抽

KRI extraction 不是黑盒模型，而是透明的 keyword dictionary。系統先把文字切成 sentences，再逐句檢查是否命中 12 類 KRI keyword。

KRI 類別	例子 keyword
supply chain risk	supply chain, supplier, shortage, logistics, raw material, delivery delay
geopolitical risk	geopolitical, trade restriction, export control, tariff, cross-strait
profitability risk	gross margin, operating margin, net income, pricing pressure, cost increase
cash flow risk	cash flow, operating cash, free cash flow, capex
cyber / digital risk	cyber, cybersecurity, data breach, system outage, ransomware
ESG / sustainability risk	esg, sustainability, carbon, emissions, climate, renewable energy

```
for sentence in sentences:
    lower_sentence = sentence.lower()

    for category, keywords in dictionary.items():
        for keyword in keywords:
            if keyword.lower() in lower_sentence:
                records.append({
                    "kri_category": category,
                    "matched_keyword": keyword,
                    "evidence_sentence": sentence,
                    "severity_hint": _severity_hint(sentence),
                })
                break
```

- 單位是 sentence，不是整篇文章，所以輸出能被 human reviewer 逐列檢查。
- 同一句話可命中多個 category，但同一 category 只記一個 keyword，避免太多 duplicate。
- source_type 會保留 news 或 annual_report，後面可比較新聞訊號與年報揭露。

6. 嚴重度怎麼判

severity_hint 是 analyst prioritization，不是最終風險評分。它根據句子裡的風險語氣字詞分成 high、medium、low，再映射成 3、2、1。

```
if any(word in lower_sentence for word in HIGH_SEVERITY_WORDS):
    return "high"

if any(word in lower_sentence for word in MEDIUM_SEVERITY_WORDS):
    return "medium"

return "low"

risk_score_hint = {"high": 3, "medium": 2, "low": 1}
```

嚴重度	代表意思	面試時怎麼講
High	句子出現 material、significant、critical、liquidity pressure 等字詞。	需要優先 validation，通常要進 management interview。
Medium	句子出現 shortage、delay、uncertainty、pressure、disruption 等字詞。	適合列入 dashboard monitoring。
Low	命中 KRI keyword，但語氣沒有明顯高/中風險字詞。	先保留 evidence，後續依來源與財務影響判斷。

這個設計的好處是可解釋：面試官問一系列 KRI 怎麼來，你可以回到 matched_keyword、evidence_sentence 和 severity words。

7. 分析怎麼變成 insight

report_generator.py 把 evidence 分成三層：來源事實、分析解讀、建議追問。這樣可以避免把模型輸出誤當成最終結論。

層次	內容	目的
來源事實	公司基本資料、新聞摘要、年報片段、KRI evidence sentence。	讓 reviewer 能回到原始資料驗證。
分析解讀	風險優先排序、商業影響、數位轉型機會。	把資料轉成 business insight。
建議追問	管理層訪談問題、資料驗證步驟、下一步分析。	把報告變成 consulting action list。

```
high = _count_severity(kri_df, "high")
medium = _count_severity(kri_df, "medium")
low = _count_severity(kri_df, "low")

overall = "High" if high > 0 else "Medium" if medium > 0 else "Low"
```

整體風險等級不是憑空產生，而是從 KRI evidence 的 high/medium/low 數量彙總而來。

8. KRI Pivot Table 怎麼看

KRI pivot table 是這個專案最適合展示的分析輸出。它等同一次做完多個 Excel COUNTIFS，計算每個 KRI 類別在 high、medium、low 各有幾筆 evidence。

```
pivot = (  
    kri_df.groupby(["kri_category", "severity_hint"])  
    .size()  
    .unstack(fill_value=0)  
)
```

```
=COUNTIFS(kri_category, "supply chain risk", severity, "high")
```

- 某 category 的 high 數量高：優先安排 source validation 和 management interview。
- 同一 category 同時出現在新聞與年報：市場和管理層都注意到該風險。
- 只出現在新聞、沒有出現在年報：可能是管理層揭露落差，也可能是市場雜訊，需要追問。
- 大多是 low：先納入 monitoring，不一定要立即升級。

9. Excel、LLM 與 Guardrails

Excel 展示 business handoff

excel_report_generator.py 產生可以交給 business user review 的 workbook。它包含 filters、freeze panes、conditional formatting、COUNTIFS、SUMIFS、XLOOKUP，不只是 CSV 匯出。

```
'=COUNTIFS(KRI_Evidence!B:B,A2,KRI_Evidence!H:H,"high")'  
'=SUMIFS(KRI_Evidence!I:I,KRI_Evidence!B:B,A2)'
```

LLM 是 optional，不是依賴

summarizer.py 只有在 use_llm=True 且 OPENAI_API_KEY 存在時才呼叫 API。預設採 rule-based brief，確保面試 demo 可重現、離線也能跑。

```
if use_llm and _can_use_llm():  
    return _generate_llm_brief(input_data, brief_type="company")  
  
return _generate_rule_based_brief(input_data, brief_type="company")
```

Guardrails

- 只整理提供的 evidence，不發明數字、公司或風險。
- Facts、Interpretation、Recommended follow-up 分開。
- KRI output 是 evidence extraction，不是最終信用、投資或營運決策。

10. 面試問答重點

Q: 這個專案最核心的價值是什麼？

它把顧問前期研究流程結構化。以前 analyst 要手動看新聞、年報和公司資料，再整理風險表；這個 MVP 把資料收集、KRI 抽取、嚴重度排序和報告生成自動化，讓人把時間花在 validation 和 business interpretation。

Q: 你怎麼確定抽出來的東西可信？

我沒有把它包裝成最終判斷，而是 evidence extraction。每一列都有 source_type、source_id、matched_keyword、evidence_sentence，reviewer 可以回到原文檢查。

Q: 為什麼不用一開始就全部用 LLM？

因為面試 MVP 要可解釋、可重現、離線也能跑。rule-based extraction 透明，面試官可以看到分類和嚴重度怎麼來；LLM 可以作為第二層 enhancement，但不能取代 evidence guardrails。

Q: 最大限制是什麼？

Keyword matching 可能漏掉語意相近但沒有命中 keyword 的句子；severity 是根據語氣字詞，不是完整財務模型；demo data 需要人確認來源品質。下一步可以加 LLM classifier、source quality score、financial ratio integration 和 time-series trend。

11. 如何執行與最後記住的主線

執行 Streamlit

```
cd C:\Projects\Industry_intelligenceAgent\industry_intelligence_agent
streamlit run app.py
```

重新產生這份 guide

```
cd C:\Projects\Industry_intelligenceAgent\industry_intelligence_agent
python scripts\generate_interview_pdf.py
```

最後記住這條線

```
raw text and tables
-> cleaned evidence
-> KRI category and severity
-> dashboard and Excel
-> consulting brief
-> human validation and next questions
```

如果面試官問很細，就回到這條線：我怎麼收資料、怎麼抽句子、怎麼分類、怎麼打優先順序、怎麼把它變成 business decision support。