

技術面試題目整理

Industry Intelligence Agent — 技術問題 + Code Block

Deloitte Digital Technology Intern · Joey Wu · 2026

每個問題分為：Q (面試官問) → 答案 → Code Block → 面試補充。Code
要能看懂邏輯，不需要背，但關鍵行要能解釋。

A pandas 資料處理

Q: 你的 KRI DataFrame 有哪些欄位？怎麼建出來的？

每一筆 KRI evidence 是一個 dict，最後用 `pd.DataFrame(records)` 一次建起來。

```
records = []
for sentence in sentences:
    for category, keywords in kri_dictionary.items():
        for keyword in keywords:
            if keyword.lower() in sentence.lower():
                records.append({
                    "kri_category": category,
                    "matched_keyword": keyword,
                    "evidence_sentence": sentence,
                    "severity_hint": _severity_hint(sentence),
                    "source_type": source_type,
                })
            break # ■■■■■■■■■■
kri_df = pd.DataFrame(records)
```

面試補充：關鍵是 `break`：同一類別一句話只記一次，避免同類別多個關鍵字重複建 row。

Q: 怎麼把 KRI 依嚴重度排序，然後取前 10 筆？

用 `map` 把 `severity` 轉成數字再 `sort`，最後 `head(10)`。

```
SEV_ORDER = {"high": 0, "medium": 1, "low": 2}
kri_df["_rank"] = kri_df["severity_hint"].str.lower().map(SEV_ORDER).fillna(3)
top10 = kri_df.sort_values("_rank").head(10).drop(columns=["_rank"])
```

面試補充：`fillna(3)` 讓沒有 `severity` 的 row 排在最後，不會讓程式 crash。

Q: 怎麼做 COUNTIFS 等效的 KRI 樞紐表？

`groupby` 兩個欄位後 `unstack`，再補齊缺少的嚴重度欄。

```
pivot = (
    kri_df
    .groupby(["kri_category", "severity_hint"])
    .size()
    .unstack(fill_value=0)
)
for col in ["high", "medium", "low"]:
    if col not in pivot.columns:
        pivot[col] = 0
pivot = pivot[["high", "medium", "low"]]
pivot["total"] = pivot.sum(axis=1)
pivot = pivot.sort_values("total", ascending=False)
```

面試補充：這等於 Excel 的 `COUNTIFS(category_col, A, severity_col, "high")`，一次算完所有組合。

Q: 怎麼讀有中文的 CSV 並避免亂碼？

用 `utf-8-sig` 讀取（處理 BOM）；寫出時也用 `utf-8-sig`。

```
import pandas as pd

# ■■
df = pd.read_csv("kri_evidence.csv", encoding="utf-8-sig", dtype=str).fillna("")

# ■■
df.to_csv("output.csv", index=False, encoding="utf-8-sig")
```

面試補充：`utf-8-sig` 會自動處理 Excel 加的 BOM (Byte Order Mark)，避免第一格亂碼。

Q: 怎麼 concat 多個 DataFrame 並去重？

`pd.concat` 後用 `drop_duplicates`，指定關鍵欄位。

```
frames = [news_kri_df, annual_kri_df] # ■■■■■■
```

面試補充：ignore_index=True 讓 index 重新從 0 開始，避免重複 index 造成後續 bug。

面試補充：嚴重度是 prioritization hint，不是財務模型。面試時主動說這句話。

面試補充：len >= 20 過濾掉單字碎片和頁碼，不會讓短到沒意義的文字變成 evidence。

面試補充：這是設計決策：同一句話可能同時是 supply chain risk 也是 geopolitical risk，兩個都要記。

```
def extract_text(pdf_path: str) -> str:
    # ■■ pdfplumber
    try:
        import pdfplumber
        with pdfplumber.open(pdf_path) as pdf:
            text = "\n\n".join(p.extract_text() or "" for p in pdf.pages)
        if text.strip():
            return text
    except:
        return ""
```

```

        return text
    except Exception:
        pass

# ■■■ PyMuPDF
try:
    import fitz
    with fitz.open(pdf_path) as doc:
        return "\n\n".join(p.get_text("text") for p in doc)
except Exception:
    return ""

```

面試補充：兩個 library 都有可能失敗：pdfplumber 對某些 PDF 格式有問題；PyMuPDF 是備援。

Q: 怎麼把長文本切成 chunk 讓 KRI 擷取更準確？

用 sliding window：每 900 個 word 一個 chunk，overlap 120 個 word。

```

def chunk_text(text: str, chunk_size=900, overlap=120) -> list[dict]:
    words = text.split()
    chunks, start, idx = [], 0, 1
    while start < len(words):
        end = min(start + chunk_size, len(words))
        chunks.append({
            "chunk_id": idx,
            "text": " ".join(words[start:end]),
        })
        if end >= len(words):
            break
        start = end - overlap # ■■■ overlap ■ word
        idx += 1
    return chunks

```

面試補充：overlap 讓跨 chunk 邊界的句子不會被切斷，KRI extraction 不會漏掉關鍵字。

Q: 怎麼找 Risk Factors 這種章節的位置？

用 regex 找各個 section heading 在文本中的起始位置，再截取到下一個 heading。

```

import re

ANCHORS = {
    "risk_factors": [r"\brisk factors\b", r"\bitem 1a\.\?\s+risk factors\b"],
    "management_discussion": [r"\bmd&a\b", r"\bmanagement.{1,15}discussion\b"],
}

def find_sections(text: str) -> dict[str, str]:
    lower = text.lower()
    hits = []
    for section, patterns in ANCHORS.items():
        for pat in patterns:
            m = re.search(pat, lower, re.IGNORECASE)
            if m:
                hits.append((m.start(), section))
                break
    hits.sort()
    result = {}
    for i, (start, name) in enumerate(hits):
        end = hits[i+1][0] if i+1 < len(hits) else len(text)
        result[name] = text[start:end][:8000] # ■■ 8000 ■
    return result

```

面試補充：Apple 10-K 的 Risk Factors 可能是 Item 1A。· regex 要能同時 match 兩種格式。

D RSS 新聞收集


```

    tmp.write(uploaded.getbuffer())
    tmp_path = pathlib.Path(tmp.name)
    try:
        result = read_annual_report_pdf(tmp_path)
    finally:
        tmp_path.unlink(missing_ok=True) # ■■■■■■■■■■

```

面試補充：finally 確保就算 read_annual_report_pdf 丟 exception，暫存檔還是會被刪掉。

Q: 怎麼用 @st.cache_data 避免重複抓同一份新聞？

加 decorator · Streamlit 會用 function 參數做 cache key · 相同參數直接回傳快取。

```

@st.cache_data(show_spinner=False)
def load_news_cached(query: str, max_articles: int) -> pd.DataFrame:
    return fetch_google_news(query, max_articles)

```

```

# ■■■■■■■■■■
# ■■ query + max_articles■■■■■■■■■■ HTTP request
news_df = load_news_cached("TSMC tariff", 10)

```

面試補充：cache_data 適合 pure function。如果 function 有 side effect (例如寫檔) 就不要 cache。

F Altair 圖表

Q: 怎麼做 KRI 嚴重度的 bar chart？

先把 severity_hint 做 value_counts · 再用 mark_bar encode x/y/color。

```

import altair as alt

sev_df = (
    kri_df["severity_hint"].str.lower()
    .value_counts()
    .reindex(["high", "medium", "low"], fill_value=0)
    .reset_index()
)
sev_df.columns = ["severity", "count"]
sev_df["label"] = sev_df["severity"].map(
    {"high": "High", "medium": "Medium", "low": "Low"}
)

chart = (
    alt.Chart(sev_df)
    .mark_bar(cornerRadiusTopLeft=4, cornerRadiusTopRight=4)
    .encode(
        x=alt.X("label:N", sort=["High", "Medium", "Low"], title=""),
        y=alt.Y("count:Q", title="■■■"),
        color=alt.Color("label:N",
            scale=alt.Scale(
                domain=["High", "Medium", "Low"],
                range=["#d62728", "#ff7f0e", "#2ca02c"]
            ), legend=None),
        tooltip=["label:N", "count:Q"],
    )
    .properties(height=200)
)
st.altair_chart(chart, use_container_width=True)

```

面試補充：:N 表示 nominal (類別資料) · :Q 表示 quantitative (數值)。Altair 靠這個推斷 scale 型別。

Q: 怎麼做 KRI 類別的圓餅 / 甜甜圈圖？

用 mark_arc · 設 innerRadius 就變甜甜圈圖 · theta encode 數值。

```

cat_df = kri_df["kri_category"].value_counts().reset_index()
cat_df.columns = ["category", "count"]

```

面試補充：innerRadius=0 就是一般 pie chart，innerRadius > 0 是 donut chart。

```
tmp_path = None
try:
    with tempfile.NamedTemporaryFile(delete=False, suffix=".pdf") as f:
        f.write(uploaded.getbuffer())
        tmp_path = pathlib.Path(f.name)
    result = read_annual_report_pdf(tmp_path)    # ■■■■ exception
except Exception as e:
    st.warning(f"PDF ■■■■■{e}")
```

```
# ██████████
# app.py      - Streamlit UI layer
# src/       - Business logic KRI ██████████ PDF ██████████
```

```
# ■■■ FastAPI ■■■■
from fastapi import FastAPI
from src.kri_extractor import extract_kri_mentions
from src.report_generator import generate_chinese_report

app = FastAPI()

@app.post("/analyze")
def analyze(company: str, text: str):
    kri_df = extract_kri_mentions(text, ...)
    report = generate_chinese_report(...)
    return {"kri": kri_df.to_dict(), "report": report}
```

面試補充：面試時說「src/ 和 app.py 完全解耦，換 UI 層不需要動業務邏輯」，展示架構思維。

速查：常用 pandas 操作

操作	Code	說明
讀 CSV	pd.read_csv(path, dtype=str).fillna("")	dtype=str 避免自動轉型
寫 CSV (中文)	df.to_csv(path, encoding='utf-8-sig')	Excel 開不亂碼
過濾 rows	df[df['severity'] == 'high']	布林 indexing
計算各值數量	df['col'].value_counts()	最常用的聚合
pivot 計數	df.groupby(['A','B']).size().unstack()	COUNTIFS 等效
concat + 去重	pd.concat(frames).drop_duplicates(subset=[])	合併多個 df
排序	df.sort_values('col', ascending=False)	降序
取前 N 筆	df.head(10)	預覽 / 限制輸出
新增欄	df['new'] = df['a'].map({'x':1,'y':2})	map 做 label encode
轉 dict list	df.to_dict(orient='records')	給 JSON / API 用